CQA: контроль качества диалогов

fantastik 4 · Freedom Broker CQA Hackathon · Data Challenge 2026

- Оцениваем **каждый** чат и звонок оператора по версионируемому чек-листу: вердикт, обоснование, номер реплики, N/A, флаг грубой ошибки.
- ≈ 30 с на диалог (режим по критерию), ≈ $0.003 на **своём** H200: данные клиентов по умолчанию не уходят в облако (запасная цепочка и часть ASR — облачные).
- Апелляция → решение ревьюера → пересчёт итога. Правила QA меняет сам, без разработчика.
- Встраивается в Dynamics 365 (`mountCqa(root, {apiBase})`).

Дальше — живой продукт: чек-лист → диалоги → оценка → результат → апелляция → переоценка.

Почему этому можно доверять

Совпадение с разметкой, 60 DEV-чатов	≈ **0.93** в двух прогонах 0.931–0.939 (RU 0.87–0.92 · KZ 0.96 · EN 0.95–0.96)
Сверка с публичной разметкой других команд	5 наборов: **94.6–99.3%** с нашей разметкой, 92.5–96.8% с моделью; шестая ручная — 86.7% (иначе читает C7); слепая ручная (14 диалогов): 84% / 76%
Сравнено моделей и режимов	≈ 15, включая Gemini 4, Grok 4.7, DeepSeek-V4 и казахские LLM: никто не лучше gemma-4 31B
Воспроизводимость между прогонами	**99.6%** вердиктов в раунде 3 (до финальных правил; на финальных не перемерялась); 99.0% на контрольных настройках
Контрольный прогон	одна команда → `results/prod/results.json`, без ручных правок

Модель недоступна → автоматически запасная цепочка. Битая запись → строка `error` в файле, а не падение прогона.

Звонки: зачем свой транскрипт

Транскрипт звонков организаторов для QA непригоден: «идентификацию успешно проеданная». Неверный текст даёт неверную оценку и неверное решение по оператору.

- По умолчанию **FreedomSpeech**, собственное STT Freedom; рядом 8 моделей с бейджем качества и «Вставить свой».
- «Распознать заново»: аудио → текст → роли → маскирование ПДн **на нашей модели**; ASR на T-one и GigaAM — 19–30 с в среднем.
- **Свой звонок или чат**: загрузили файл → язык по звуку (казахский распознаётся с `kk`, защита от зацикливания ASR) → роли, маскирование → обычный цикл оценки, апелляции и «Выгрузить дело».

5 DEV-звонков	CER к FreedomSpeech
T-one + pyannote (наш H200)	**11.8%**
GigaAM-v3 + pyannote (наш H200)	12.6%
Gemini 3.5 Transcribe	14.5%
KuSpeech multilingual	15.8%
Whisper large-v3	20.3–30.9%

Выбор модели · запасной слайд

	Совпадение, 60 DEV-чатов
gemma-4 31B, по критерию	**0.93–0.94**
Qwen3.8-27B / Flash-Next	0.91–0.92
DeepSeek-V4.1 / Kimi-K2.6	0.90 / 0.85
Gemini 4 Argon, Grok 4.7, DeepSeek-V4-Pro	на 1–3 п.п. ниже gemma на тех же чатах
ансамбль из 3 судей	ничья с gemma

- Голосование k=3 замерили — не помогает. Файнтюн не делали: на 65 диалогах его нельзя честно проверить.
- Лучшая по KazMMLU казахская модель (`issai/Qwen3.5-35B-A3B-Kazakh` , у нас на H200) судит хуже gemma. На казахских чатах gemma и так 0.96.

Честно о границах · запасной слайд

- Эталона организаторов нет (#2966). Наша разметка — консенсус моделей, плюс 20 ручных решений, плюс сверка с разметкой других команд (`bench/gold/README.md`).
- Правила подбирались на тех же 65 DEV-диалогах, поэтому 0.93–0.94 на DEV — оценка сверху: на новых чатах ожидаем ≈ 0.91–0.93.
- По звонкам совпадение с чужой разметкой 69% (ручная, 16 клеток) и 79% (два прохода Claude, 24 клетки): на звонках точность не заявляем. CER — это согласие с FreedomSpeech, а не точность.
- Самый чувствительный критерий — «Завершение» (c07). По тексту чек-листа нужен итог или предложение помощи **и** прощание; одно «Пожалуйста, хорошего дня!» = Нет (#2814: «перечитайте чек-лист»). На DEV c07 = Нет в 50 из 60 чатов, и в 32 из них балл теряется только на c07 (`results/dev`). Если эталон трактует мягче, мы теряем почти целый критерий из 8 — правило в чек-листе редактируется за минуту.

Репозиторий: github.com/batyrkhan4ikdev/data-challenge_110726 · `results/dev` , `results/prod` .