# CQA: контроль качества диалогов

**fantastik 4** · Freedom Broker CQA Hackathon · Data Challenge 2026

- Оцениваем **каждый** чат и звонок оператора по версионируемому чек-листу: вердикт, обоснование, номер реплики, N/A, флаг грубой ошибки.
- ≈ 30 с на диалог (режим по критерию), ≈ $0.003 на **своём** H200: данные клиентов по умолчанию не уходят в облако (запасная цепочка и часть ASR — облачные).
- Апелляция → решение ревьюера → пересчёт итога. Правила QA меняет сам, без разработчика.
- Встраивается в Dynamics 365 ( `mountCqa(root, {apiBase})` ).

**Дальше — живой продукт:** чек-лист → диалоги → оценка → результат → апелляция → переоценка.

## Почему этому можно доверять

| | |
|---|---|
| Совпадение с разметкой, 60 DEV-чатов | ≈ **0.93** (RU 0.92 · KZ 0.96 · EN 0.96) |
| Наша разметка vs разметка 5 других команд (их публичные репо) | **94.6–99.3%**; модель vs они: 92.5–96.8% |
| Сравнено моделей и режимов | ≈ 15, включая Gemini 4, Grok 4.7, DeepSeek-V4 и казахские LLM: никто не лучше gemma-4 31B |
| Воспроизводимость между прогонами | **99.6%** вердиктов |
| Контрольный прогон | одна команда → `results/prod/results.json`, без ручных правок |

Модель недоступна → автоматически запасная цепочка. Битая запись → строка `error` в файле, а не падение прогона.

## Звонки: зачем свой транскрипт

Транскрипт звонков организаторов для QA непригоден: «идентификацию успешно проеданная». Неверный текст даёт неверную оценку и неверное решение по оператору.

- По умолчанию **FreedomSpeech**, собственное STT Freedom; рядом 8 моделей с бейджем качества и «Вставить свой».
- «Распознать заново»: аудио → текст → роли → маскирование ПДн **на нашей модели**, ≈ 40 с.

| 5 DEV-звонков | CER к FreedomSpeech |
|---|---|
| T-one + pyannote (наш H200) | **11.8%** |
| GigaAM-v3 + pyannote (наш H200) | 12.6% |
| Gemini 3.5 Transcribe | 14.5% |
| KuSpeech multilingual | 15.8% |
| Whisper large-v3 | 20.3–30.9% |

## Выбор модели · запасной слайд

| | Совпадение, 60 DEV-чатов |
|---|---|
| **gemma-4 31B, по критерию** | **0.93–0.94** |
| Qwen3.8-27B / Flash-Next | 0.91–0.92 |
| DeepSeek-V4.1 / Kimi-K2.6 | 0.90 / 0.85 |
| Gemini 4 Argon, Grok 4.7, DeepSeek-V4-Pro | на 1–3 п.п. ниже gemma на тех же чатах |
| ансамбль из 3 судей | ничья с gemma |

- Голосование k=3 замерили — не помогает. Файнтюн не делали: на 65 диалогах его нельзя честно проверить.
- Лучшая по KazMMLU казахская модель ( `issai/Qwen3.5-35B-A3B-Kazakh` , у нас на H200) судит хуже gemma. На казахских чатах gemma и так 0.96.

## Честно о границах · запасной слайд

- Эталона организаторов нет (#2966). Наша разметка — консенсус моделей, плюс 20 ручных решений, плюс сверка с разметкой других команд ( `bench/gold/README.md` ).
- Правила подбирались на тех же 65 DEV-диалогах: 0.94 на DEV — потолок, ожидаем ~0.93 ± 0.02.
- По звонкам совпадение с чужой ручной разметкой 69–79%: на звонках точность не заявляем. CER — это согласие с FreedomSpeech, а не точность.

**Репозиторий:** github.com/batyrkhan4ikdev/data-challenge_110726 · `results/dev` , `results/prod` .